

基于改进卷积网络的实时交通标志检测方法

童英^{1*}, 杨会成²

(^{1,2}安徽工程大学 电气工程学院, 安徽 芜湖 241000)

摘要: 交通标志检测在驾驶辅助系统和交通安全方面发挥着重要作用。卷积神经网络在计算机视觉任务上取得了重大的突破,并在交通标志检测方面取得了巨大的成功。然而,现有的检测方法通常达不到实时的效果。因此,本文提出一种改进卷积神经网络交通标志检测方法,通过结合特征级联,难分类负样本采集,多尺度训练和关键参数的适当校准等多种方法来改进快速卷积神经网络模型。首先预训练模型,以便产生否定;然后,使用难分类负样本采集将负样本输入到网络中,提升模型的判别能力;最后,使用多尺度训练过程中的特征级联策略来进一步提升模型的性能。本文利用 Tensorflow 框架对所提出的方法的有效性进行了仿真分析。在德国交通标志检测数据集上的仿真结果表明,与现有技术相比,本文提出的方法能够获得更高的检测速率,检测速度可以提升到处理每张图像仅需 0.016 秒。

关键词: 神经网络; 交通标志检测; 特征拼接; 难分类负样本采集; 多尺度训练;

中图分类号: TP181

文献标志码: A

Real-time traffic sign detection method based on improved convolution network

Tng Ying^{1*}, Yang huicheng²

(^{1,2}College of Electrical Engineering, Anhui Polytechnic University, Wuhu 241000, China)

Abstract: Traffic sign detection plays an important role in driving assistance systems for traffic safety. Convolutional neural networks have made a great breakthrough in computer vision tasks and achieved great success in traffic sign detection. However, the existing methods usually do not achieve real-time detection. Therefore, this paper proposes a modified traffic sign detection method based on convolutional neural network. The fast convolutional neural network model is improved by combining a number of strategies, including feature concatenation, hard negative mining, multi-scale training and proper calibration of key parameters. First, the model is pre-trained to produce negatives. Then, hard negative mining is used to add negative samples into the network. Finally, a feature concatenation strategy during multi-scale training process is employed to enhance the performance of the model. This paper uses the German traffic sign detection datasets to simulate the effectiveness of the proposed method in Tensorflow framework. The simulation results show that compared with the existing methods, the proposed method can obtain a higher detection rate, and detection speed is able to achieve 0.016 seconds per image.

Keywords: neural networks; traffic sign detection; feature concatenation; hard negative mining; multi-scale training;

OCIS codes: 100.4996; 100.5010; 100.2000; 100.3008

1 引言

收稿日期: 年-月-日; **修回日期:** 年-月-日; **录用日期:** 年-月-日

基金项目: 安徽省高校自然科学研究重点项目 (KJ2018A0122)

作者简介: 杨会成 (1970 年) 男, 硕士, 教授, 主要研究方向为图像信息处理、疲劳驾驶检测等。

童英 (1993 年), 女, 硕士研究生, 主要研究方向为图像处理与模式识别。

*E-mail: 864844537@qq.com

道路交通事故已成为全球最常见的死因之一^[1]。高级驾驶员辅助系统帮助驾驶员了解交通标志位置以及沿道路行驶的规则并通知驾驶员标志的含义，减少发生事故的可能性。交通场景分析是计算机视觉和智能系统中的一个非常重要的课题^[2-5]。因此，设计一个自动实时驾驶辅助系统来检测和识别交通标志是非常重要的。

目前提出的交通标志检测方法分为三类：基于颜色，基于形状和基于滑动窗口。基于颜色的方法通常使用颜色信息对像素进行分类以提取候选符号^[6-7]。一些方法将候选交通标志提取为最大稳定极值区域^[8]。文献[9]提出了基于 Ohta 空间的颜色概率模型，以计算交通标志颜色概率图。基于形状特征的方法通常会为每个类别设计了一组模板以匹配形状^[10]。文献[11]采用了定向梯度直方图特征和支持向量机分类器来检测交通标志并取得了很好的成绩。文献[12]同时利用颜色与形状特征，在图像的红色边缘位图中采用圆霍夫变换检测圆形。其他类似 Hough 的方法包括顶点和平分线变换^[13]，双边中式变换^[14]，直立三角形单目标投票^[15]和直立椭圆单目标投票^[15]。还有一些研究提出用智能交通标志分类系统来对基于表意文字的交通标志进行实时分类^[16-18]。基于滑动窗口的方法已被广泛应用于目标检测，主要使用级联 AdaBoost 分类器，其中弱学习者经常使用 Haar-like 特征^[19]。

最近，深度卷积神经网络在物体检测中取得了巨大的成功。空间金字塔池化网络（Spatial Pyramid Pooling in Deep Convolutional Networks, SPPnets）是提出通过共享卷积特征映射来提高速率^[20]。由于 SPPnet 方法仅计算整个输入图像的卷积特征映射，并且培训是一个多阶段的流程，而不是端到端的方法，导致 SPPnet 有着明显的缺。更快卷积神经网络(Faster region-based convolutional neural networks ,Faster R-CNN)能够在共享的端到端检测器上进行培训卷积特征并显示出更优的准确性和速度^[21]。快速神经网络仍然使用选择性搜索方法生成 2000 个区域提案^[22]。Faster R-CNN 引入了一种训练方案，该方案在对区域提议的微调和对对象检测的微调之间交替,并产生两个任务之间共享的具有卷积特征的统一网络^[23]。Matthew D.Zeiler 等^[24]提出的 ZF 网络通过使用可视化技术展示了神经网络各层的结构和用处，并获得 2013 年大规模视觉识别挑战赛第一名的佳绩。YOLO(You Only Look Once)网络将物体检测作为回归问题求解^[25]。

但是，上述方法在检测速率上达不到实时的效果，所以本文旨在实时处理交通标志检测。在这项工作中，本文基于 Faster R-CNN 方法提出了一种新快速卷积神经网络(New Faster region-based convolutional neural networks,NF R-CNN)模型。具体方法步骤如下文所示。

2 基本原理

2.1 交通标志识别方案

本文的方法遵循类似深度学习方法 Faster R-CNN，此方法已被证明是最先进的对象检测通用学习方案^[23]。它基本上由两个步骤组成，第一个步骤是一个区域提案网络（Regional proposal network，RPN）生成可能包含对象的区域提议列表，或称为感兴趣区域（RoIs）。第二个步骤是将 Fast R-CNN 网络用于将图像

区域分类为象（和背景）和地区边界。这两部分共用特征提取中的卷积层参数，使得此架构以极具竞争力的速度完成对象检测任务。本文建议扩大用于交通标志检测的 Faster R-CNN 体系结构，以提高召回率和准确性，并通过以下流程训练交通标志检测模型，结构如图 1 所示。




图 1 程序流程图

Fig.1 Program flow chart

首先，基于 Faster R-CNN 模型，使用德国交通标志检测基准(German Traffic Sign Detection Benchmark, GTSDb)测试预先训练好的模型，以便产生强烈的否定。然后，难分类负样本（hard negative samples,HNS）作为培训的第二步，将负面信息输入到网络中。最后，在微调过程中，本文应用多尺度训练过程，并且采用特征级联策略来进一步提升模型的性能。对于整个培训过程，加入类似端到端培训策略。本文接下来将详细介绍方案中的关键步骤。

2.2 NF R-CNN 网络结构

传统的 Fast R-CNN 网络，是在最后的特征映射层上执行 RoI 池以生成该区域的特征，然后由网络的分类部分进一步分析。这种巧妙的设计使得分类网络可以利用 RPN 计算的特征，节省了大量不必要的计算。然而，更深卷积层输出中的特征具有更宽的感受域，导致一些重要特征被忽略，所以，这种方法并不是最优的^[26]。为了捕获更精细的 RoI 细节，本文建议通过组合多个卷积层的特征映射来改进 RoI 池，包括低级和高级特征。本文建议连接多个卷积特征映射的池化结果，以生成检测任务的最终池化特征。首先，将这些结果特征连接起来并重新缩放以匹配特征的原始比例。然后，应用 1×1 卷积以匹配原始网络的信道数。与 RPN 中的最终功能图一起将它们组合在一起产生最终的池化功能。接着，将这些结果特征串联起来。最后是 1×1 卷积用于匹配原始网络的信道数量。详细架构如图 2 所示。

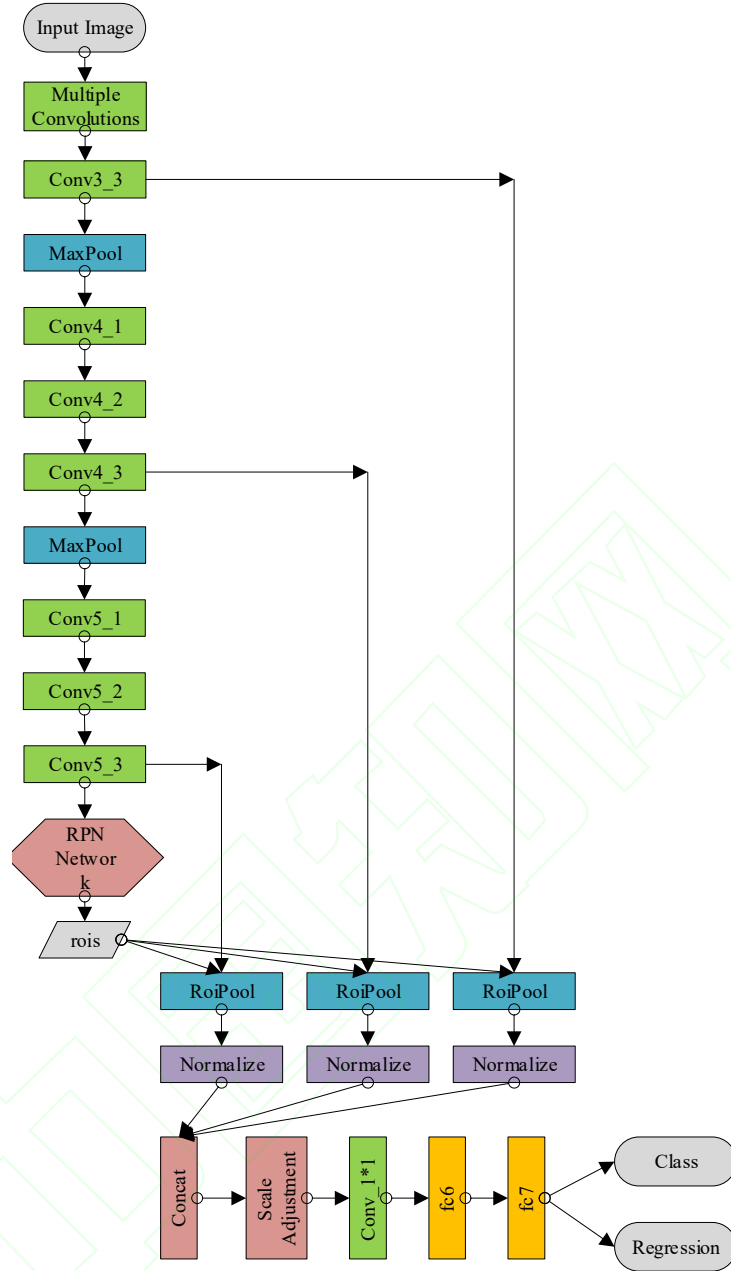


图 2 NF R-CNN 神经网络结构

Fig.2 NF R-CNN neural network structure

2.3 改进模型的方法

本节内容介绍了应用于模型的 4 种方法，本文将这些方法进行融合，以提高模型的各项性能。方法有效性将进行仿真验证，具体步骤如下文所示。

方法一：难分类负样本采集。

HNS 的采集已被证明是一种为提高深度学习表现有效的策略。将 HNS 再次加入网络，可以减少误报，加强本文的培训效果。本文明确添加一些难以消除的内容进入 RoIs 来微调模型，并平衡比率前景和背景约为 1:3。算法如下：

设 N_t 是将作为负样本集， P_t 是一个正样本集，其中 t 表示在训练过程中可以在多个时间收集样本。设

D_0 为原始训练集，由原始的一组正例 P_0 和一组负例 N_0 组成：

$$D_0 = P_0 \cup N_0, \quad (1)$$

一旦训练过程完成，本文将网络运行到图像集 N ，本文从中收集假正 F_I 的子集，将其添加到原始的负集 N_0 中：

$$N_I = N_0 \cup F_I, \quad (2)$$

网络的输出选择集 F_I 。在每轮训练期间，根据其分数对误报进行排序，并选择预定数量的样本。为了在每轮训练后保持相同的正负样本比例，本文增加了正样本的数量。包含面 T_I 的一组新图像被添加到原始的一组正例 P_0 中

$$P_I = P_0 \cup T_I, \quad (3)$$

在完成 D_I 训练后，重复上述训练和增加训练样本的过程：

$$N_{T+I} = N_I \cup F_{T+I}, \quad (4)$$

$$P_{T+I} = P_I \cup T_{T+I}, \quad (5)$$

$$D_{T+1} = P_{T+1} \cup N_{T+1}, \quad (6)$$

因此，集合 N_{T+I} ， P_{T+I} 包含比集合 N_I ， P_I 更多数量的负和正样本。

方法二：锚的调整

在这项工作中，本文已经调整了 Faster R-CNN 体系结构的几个关键的超参数，研究发现，本文算法最关键的是数量 RPN 部分中的锚点数量。传统的 Faster R-CNN 使用 9 个锚无法召回小物件。然而，对于交通标志检测任务，目标的尺寸往往较小，特别是在不受约束的情况下的交通标志检测。因此，本文不是使用默认值设置，而是添加一个 64×64 的尺寸组，从而增加了锚的数量。仿真表明，这种修改明显增加了模型检测的精确度和召回率。

方法三：模型预训练

为了使 Faster R-CNN 适应交通标志检测，本文选择在交通标志数据集上微调预先训练好的模型。作为一个被广泛确认的数据集（包含无约束的交通标志），德国交通标志识别基准(German Traffic Sign Recognition Benchmark,GTSRB)可以用来验证模型，首先对本文的模型进行预训练交通标志数据集以及 HNS。另外，HNS 的采集是在对这个数据集进行预训练时必不可少的，此步骤可以使生成的误报最小化。这种预训练的策略，加上 HNS 的采集，再次提升了模型的准确率。

方法四：多尺度训练

Faster R-CNN 结构通常采用固定比例训练所有的图像。通过将图像大小调整为随机比例，从而提高在尺度不变性方面的性能。在这项工作中，本文为每个图像在输入网络之前随机分配三个比例中的一个。研究表明多尺度的训练使本文的模型适用于不同大小的图片，并提高了基准检测的性能结果。

3 仿真设置及结果分析

在本节中，本文采用基准数据集进行实验，以展示本文方法的有效性。GTSDB 数据集包含 900 个高分辨率的交通标志自然场景图像，每幅图像为 1360×800 像素，交通标志尺寸从 16×16 像素到 128×128 像素。它使用 600 张图像进行训练，并使用 300 张图像进行测试。GTSRB 数据集包含 39209 个训练图像和 12630 个图像测试。这些标志分为三大类，其中包括德国交通标志的 43 个小类，大小从 15×15 像素到 250×250 像素，如图 3 所示。




图 3 交通标志的三个超分类示例。(a)指示； (b)禁止； (c)警告

Fig.3 Three super classification examples of traffic signs. (a) Mandatory; (b) Prohibitory; (c) Danger


本文采用 Tensorflow 框架来训练本文的深度学习模型。VGG16 卷积神经网络结构是由视觉几何组开发的，该深度学习神经网络在 2014 年度大规模视觉识别挑战赛赢得第一的称号。现如今，VGG16 依然被认为是一个优秀的视觉模型。由于该模型有 16 层的深度，足以进行交通标志图片检测，并且，该网络在训练和测试时使用了多尺度做数据增强。所以 VGG16 被选定为本文的预训练模型，并将改进后的模型与 VGG16 的原始模型进行仿真结果对比。

第一步，在 GTSDB 数据集上预训练 VGG16 模型，进行 80000 次迭代，学习率设置为 0.0001。在此培训过程中，图像首先被重新缩放，同时始终保持原始宽高比。短边重新缩放为 600，长边为 1000。并使用水平翻转策略，以达到数据增强的目的。在训练过程中，12 个锚点用于 RPN 部分，覆盖总尺寸为 64×64,128×128,256×256,512×512 和三种纵横比，包括 1: 1,1: 2 和 2: 1。非极大值抑制(Non-Maximum Suppression,NMS)算法之后，保留了 1800 个区域提议。对于 Faster R-CNN 分类部分，如果 IoU 大于 0.5，则 RoI 将被视为前景，否则将视为背景。为了平衡前景和背景的数量，对这些 RoI 进行采样以保持前景和背景之间的比例为 1:3。


第二步，将上述数据集输入网络。当输出区域的信心评分高于 0.8，而 IoU 值与任何地面实况注释均

小于 0.5 时，则被视为 HNS。然后采用固定学习率为 0.0001 的回归程序进行 10000 次迭代，确保这些 HNS 与其他样本的 RoI 一起被选择。最后，通过 GTSDb 数据集进一步对结果模型进行微调，以产生本文的最终检测模型。


为了在 GTSDb 基准测试中检测本文的交通标志检测模型的性能，对于每个图像，除了执行水平翻转之外，本文还在将其较短的一面反馈到网络之前随机调整大小。与第一步中采取的策略类似，本文确保较长的一面像素不超过 1250。在训练过程中，本文连接了从 conv3_3, conv4_3 和 conv5_3 图层汇集的功能。在连接后使用的标度可以是细化的也可以是固定的。本文在训练和测试阶段对二进制大对象使用 4700 的固定比例。本文使用 0.001 的固定学习率对模型进行了 5000 次迭代的微调，以获得本文的最终模型。由于道路环境复杂，且图片分辨率低，ZF 模型及 VGG16 模型会存在部分漏检和误检的情况，检测结果示例如图 4 所示。



(a)



(b)



(c)

图 4 三种方法检测结果示例。(a)ZF; (b)VGG16; (c)NF R-CNN

Fig 4 Example of three methods test resultss. (a)ZF; (b)VGG16; (c)NF R-CNN

第三步，对于测试阶段，按照与第一阶段相同的原则对图像进行重新缩放。对于每张图像，RPN 网络在区域提案生成步骤中生成总共 80 个区域提案。如果分类置信度得分大于 0.8，则选定的区域提案将被视为交通标志。在本文的方法中，NMS 阈值设置为 0.3。为了进行分析，本文还在实验中输出了置信度得分大于 0.001 的所有区域提案。

本文采用精确度、召回率以及受试者工作特征曲线（receiver operating characteristic curve，ROC）下的面积（Area Under Curve，AUC）作为评价标准。精确率表示预测为正类样本中真正为正类样本的比例。召回率表示预测为正类样本被正确分类的比例。时间是每个图像处理的平均运行时间.AUC 是精度和召回曲线下的区域。表 1 显示了本文的方法的精确度和召回率的数值。随着阈值的增加，精确度越高，召回率越低。当 $t=0.4$ 或 $t=0.5$ 时，模型的整体性能更高效且更稳健。

表 1 不同时间阈值下的精确度和召回率数值

Table 1 Accuracy and recall rate values at different time thresholds


Threshold (t)	0.1	0.2	0.4	0.5	0.6	0.7
Precision	0.7654	0.8826	0.9542	0.9688	0.9835	1
Recall	0.9542	0.9403	0.9125	0.8623	0.7854	0.6281

为了分析测试结果，本文设置 $t=0.5$ 以确保高精度的检测，当交通标志的置信度得分低于阈值 t 时，本文过滤那些交通标志的候选区域。表 2 显示了本文在数据集上呈现的三种模型的精确度（P）和召回率（R）。图 5 显示了三个超类别 PR 曲线。

表 2 三种方法分类结果比较

Table 2 Comparison of classification results of three methods

		Mandatory(%)	Prohibitory (%)	Danger (%)	Time (s)
Model-ZF	Precision	91.89	97.68	98.65	0.133
	Recall	79.11	70.56	93.15	
Model-VGG16	Precision	98.85	99.44	99.86	0.130
	Recall	75.23	69.26	87.84	
Model-NF R-CNN	Precision	98.10	99.22	99.23	0.016
	Recall	80.31	72.96	94.78	



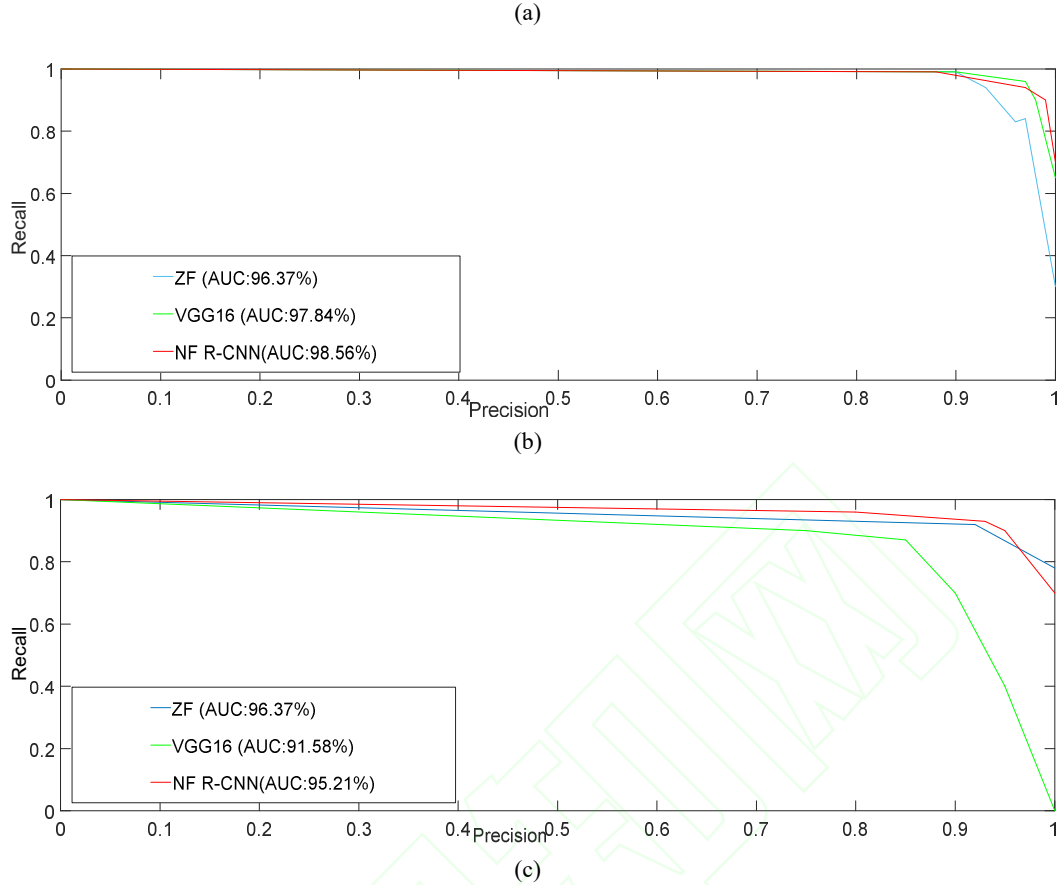


图 5 三个超分类的 PR 曲线图。(a)指示；(b)禁止；(c)警告

Fig.5 The precision-recall curves of the three super categories.(a) Mandatory; (b) Prohibitory; (c) Danger

从表 2 中，本文模型虽然在精确上略次于 VGG16 模型，但明显高于 ZF 模型，且可以看到改进的模型比其他模型更快。每张图片只需 0.016 秒。当 $t=0.5$ 时，本文模型预测的召回率最好。从图 5 中可看出，第一点，由于 ZF 模型相比较于其他两种模型，卷积深度较浅，导致 ZF 模型在指示标志和禁止标志中的 AUC 值均低于 VGG16 模型和本文模型。第二点，VGG16 模型简化了卷积神经网络的结构，但需要非常大的训练特征数量，而禁止标志分布密集且尺寸太小，导致特征不明显，所以，VGG16 模型在警告标志中的 AUC 值明显偏低，仅 91.58%。第三点，因为多种优化方法的使用均能提升模型的精确度和召回率，所以，本文模型在三种标志超类中均表现出较高的 AUC 值且稳定性最优，达到指示标志 94.47%，禁止标志 98.56% 和警告标志 95.21%。实验结果表明，HNS 的采集方法和锚的调整可以提高检测率，减少时间消耗。

表 3 AUC 值和处理时间

Table 3 The AUC values and processing times

Method	Mandatory(%)	Prohibitory (%)	Danger (%)	Time (s)
[8]	96.54	99.35	96.68	0.15
[9]	92.56	96.58	91.27	0.31
[10]	93.47	100	98.64	0.66
[11]	100	100	99.22	3.47
NF R-CNN	97.02	99.55	99.37	0.016

表 3 中显示了三个超类的交通标志的 AUC 值和运行时间。参考文献[8,9,10,11]的方法基于传统的检测

算法, 研究显示, 传统方法在检测速率方面普遍偏低, 达不到实时效果, 而本文方法不仅在 AUC 数值上显示出优越性, 在处理时间上更是达到 0.016s, 达到实时的效果。

4 结论

由于交通标志检测的重要性以及现有方法检测速率慢, 本文提出了一种基于深度学习的交通标志检测方法。首先, 本文训练了用于通用对象检测的最先进的 Faster R-CNN 框架。然后, 提出了几种有效的策略来改进用于解决交通标志检测任务的 Faster R-CNN 算法。最后, 本文在著名的测试集上进行了一系列的实验训练并比较了其他方法。实验结果表明, 比起现有方法, 本文的检测时间更趋于实时。不过, 在检测时间上, 还有望继续提高速率, 达到更高水平, 所以, 在未来的工作中, 将进一步解决所提出的用于更快速准确的交通标志检测方法的效率和可扩展性问题。

参考文献:

- [1] Stewart B T, Yankson I K, Afukaar F, et al. Road traffic and other unintentional injuries among travelers to developing countries[J]. Med Clin North Am, 2016, 100(2):331-343.
- [2] Zhang S F, Zhu T. A method of traffic sign detection and recognition based on HDR technology[J]. Laser & Optoelectronics Progress, 2018, 55(9): 091006.
张淑芳, 朱彤. 一种基于 HDR 技术的交通标志牌检测和识别方法[J]. 激光与光电子学进展, 2018, 55(9): 091006.
- [3] Hu C, Bai X, Qi L, et al. Learning discriminative pattern for real-time car brand recognition[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(6):3170-3181.
- [4] Gao D D, Xu X T, Li B. Research on application of infrared and white light mixed supplemental lighting system in intelligent transportation[J]. Infrared and Laser Engineering, 2018, 47(9): 0918006.
高东东, 徐晓婷, 李博. 红外/白光混合补光系统在智能交通中的应用研究[J]. 红外与激光工程, 2018, 47(9): 0918006.
- [5] Xu Y, Wei Z Y. An Improved Traffic Sign Image Recognition Algorithm[J]. Laser & Optoelectronics Progress, 2017, 54(2):021001.
徐岩, 韦镇余. 一种改进的交通标志图像识别算法[J]. 激光与光电子学进展, 2017, 54(2): 021001.
- [6] Fleyeh H, Davami E. Eigen-based traffic sign recognition[J]. Iet Intelligent Transport Systems, 2011, 5(3):190-196.
- [7] Khan J F, Bhuiyan S M A, Adhami R R. Image segmentation and shape analysis for road-sign detection[J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(1):83-96.
- [8] Yang Y, Luo H, Xu H, et al. Towards real-time traffic sign detection and classification[C]// IEEE, International Conference on Intelligent Transportation Systems. IEEE, 2014:87-92.
- [9] Yang Y, Wu F. Real-time traffic sign detection via color probability model and integral channel features[J]. 2014, 484:545-554.
- [10] Liang M, Yuan M, Hu X, et al. Traffic sign detection by ROI extraction and histogram features-based recognition[C]// International Joint Conference on Neural Networks. IEEE, 2013:1-8.
- [11] Wang G, Ren G, Wu Z, et al. A hierarchical method for traffic sign classification with support vector machines[J]. 2013:1-6.
- [12] Wang G Y, Jin Y S, Ren G H, et al. High-performance VLSI architecture for traffic sign detection[J]. Infrared and Laser Engineering, 2018, 47(9): 0926001.

王刚毅,金炎胜,任广辉,等. 高性能交通标志检测模块的 VLSI 结构设计[J]. 红外与激光工程, 2018, 47(9): 0926001.

- [13] Belaroussi R, Tarel J P. Angle vertex and bisector geometric model for triangular road sign detection[C]// Applications of Computer Vision. IEEE, 2009:1-7.
- [14] Belaroussi R, Tarel J P. A Real-time road sign detection using bilateral Chinese transform[C]// International Symposium on Advances in Visual Computing. Springer-Verlag, 2009:1161-1170.
- [15] Houben S. A single target voting scheme for traffic sign detection[C]// Intelligent Vehicles Symposium. IEEE, 2011:124-129.
- [16] Mammeri A, Khiari E H, Boukerche A. Road-sign text recognition architecture for intelligent transportation systems[C]// Vehicular Technology Conference. IEEE, 2014:1-5.
- [17] Yin S, Ouyang P, Liu L, et al. Fast traffic sign recognition with a rotation invariant binary pattern based feature[J]. Sensors, 2015, 15(1):2161-2180.
- [18] Mathias M, Timofte R, Benenson R, et al. Traffic sign recognition — How far are we from the solution?[C]// International Joint Conference on Neural Networks. IEEE, 2013:1-8.
- [19] Ruta A, Porikli F, Watanabe S, et al. In-vehicle camera traffic sign detection and recognition[J]. Machine Vision & Applications, 2011, 22(2):359-375.
- [20] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Trans Pattern Anal Mach Intell, 2015, 37(9):1904-1916.
- [21] Girshik R. Fast R-CNN[C]// IEEE International Conference on Computer Vision. IEEE, 2015:1440-1448.
- [22] Uijlings, J. R R, Sande V D, et al. Selective search for object recognition[J]. International Journal of Computer Vision, 2013, 104(2):154-171.
- [23] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[C]// International Conference on Neural Information Processing Systems. MIT Press, 2015:91-99.
- [24] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[J]. 2013, 8689:818-833.
- [25] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection[J]. 2015:779-788.
- [26] Sun X, Wu P, Hoi S C H. Face detection using deep learning:An improved faster RCNN approach[J]. Neurocomputing, 2018.

网络首发:

标题: 基于改进卷积网络的实时交通标志检测方法

作者: 童英, 杨会成

收稿日期: 2018-09-25

录用日期: 2018-10-22

DOI: 10.3788/lop56.071003

引用格式:

童英, 杨会成. 基于改进卷积网络的实时交通标志检测方法[J]. 激光与光电子学进展, 2019, 56(07): 071003.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文: