

基于改进深度卷积神经网络的交通标志识别

马永杰, 李雪燕, 宋晓凤

(西北师范大学物理与电子工程学院, 兰州 730070)

摘要 在实际交通环境中, 所采集到的交通标志图像质量往往受到运动模糊、背景干扰、天气条件以及拍摄视角等因素的影响, 这对交通标志自动识别的准确性、实时性和鲁棒性提出了很大的挑战。为此提出了改进深度卷积神经网络 AlexNet 的分类识别算法模型, 该模型在传统 AlexNet 模型基础上, 以真实场景中拍摄的交通标志图像数据集 GTSRB 为研究对象, 将所有卷积层的卷积核修改为 3×3 大小, 为了预防和减少过拟合的出现在 2 个全连接层后加入 dropout 层, 并且为了提高交通标志识别精度, 在网络模型第五层后增加两层卷积层。实验结果表明, 改进后 AlexNet 模型在交通标志识别方面具有一定的先进性和鲁棒性。

关键词 图像处理; 卷积神经网络; 交通标志识别; 改进 AlexNet 模型; 可视化

中图分类号 TP391.7

文献标志码 A

Traffic sign recognition based on improved deep convolution neural network

MA Yong-Jie, LI Xue-Yan, SONG Xiao-Feng

(School of Physics and Electronic Engineering, Northwest Normal University, Lanzhou 730070, China)

Abstract In the actual traffic environment, the quality of the collected traffic signs is often influenced by the factors such as motion blur, background interference, weather conditions and shooting angle, this poses a great challenge to the accuracy, real-time and robustness of traffic signs automatic identification. A classification recognition algorithm model of improved deep convolution neural network AlexNet is proposed. On the basis of traditional AlexNet model, this model takes the traffic sign image data set GTSRB taken in the real scene as the research object, modifies the convolution kernel of all the coiling layers to $3 * 3$, in order to prevent and reduce the occurrence of over fitting, the dropout layer is added after 2 fully connected layers. In order to improve the accuracy of traffic sign recognition, two layers of convolution layer are added after the fifth layer of the network model. The experimental results show that the improved AlexNet model is advanced and robust in traffic sign recognition.

Keywords Image processing; convolution neural network; traffic sign recognition; improved AlexNet model; visualization

OCIS codes 100.0100; 200.4260; 100.3008; 150.1135

1 引言

交通标志识别是智能交通系统的重要组成部分^[1], 它能够辅助驾驶减少驾驶员的驾驶疲劳, 保证出行安全, 在交通安全运行方面具有重大的现实意义。交通标志识别往往是在汽车运行过程中和复杂的室外交通环境下进行的, 比一般静止的事物识别更难, 主要体现在运动

收稿日期: 年_月_日; **收到修改稿日期:** 年_月_日

基金项目: 国家自然科学基金 (41461078)

作者简介: 李雪燕 (1992—), 女, 硕士研究生, 主要从事图像处理、人工智能方面的研究。

E-mail: lxyrxn@163.com

导师简介: 马永杰 (1967—), 男, 博士, 教授, 主要从事图像处理、人工智能、测控技术等方面的研究。E-mail: myjmyj@163.com

模糊、复杂多变的光照（天气）条件^[2]、背景环境干扰、拍摄角度使交通标志位置倾斜等问题。

为了解决这些问题，大量的复杂算法被提出，深度学习是目前在目标识别方面应用最多的方法，而深度学习中最著名的就是卷积神经网络^[3,4,5,6]。2012 ILSVRC 竞赛（Large Scale Visual Recognition Challenge）中，AlexNet 模型赢得了第一名，刷新了 Image Classification 的纪录，一举奠定 Deep Learning 在计算机视觉中的地位，成为 CNN 领域内具有重要历史意义的一个网络模型。AlexNet 模型及其改进 AlexNet 模型被大量研究和使使用。2017 年，Dang 等^[7]利用 AlexNet 模型高效的训练、稳定的收敛速度等优势，验证了深度学习方法在遥感影像地表覆盖分类评价中的有效性。2017 年，中国科学院的 Lv 等^[8]针对医学图像改进 AlexNet 模型，取得了较好的测试结果。2017 年，Zhang 等^[9]提出一个修改过的 AlexNet 网络来估计静止图像中的人数，证明了该方法的有效性。2018 年，Chen 等^[10]在多聚焦图像融合的过程中，在原有的 AlexNet 网络模型基础上对卷积核大小，步长等进行改进，利用改进后的深度学习网络特有的得分机制对聚焦图像块与散焦图像块进行分类。因此，利用 AlexNet 模型分类优势，考虑到交通标志识别应用中对实时性和准确性有较高的要求，对 AlexNet 进行改进并加以利用。

2 卷积神经网络

卷积神经网络（convolutional neural network, CNN）是深度学习中研究和应用较为广泛的一个分支，是一种专门用来处理具有类似网络数据结构的神经网络。CNN 包括卷积层（convolution layer）、池化层（也称亚采样层，pooling layer）、全连接层（full connection layer）等主要结构。

卷积神经网络学习图像的特征是靠卷积层和池化层来实现的。卷积运算主要作用为提取图像特征，卷积公式如式（1）：

$$y(n) = x(n) * h(n) \quad (1)$$

其中， $*$ 表示卷积， $x(n)$ 为卷积对象， $h(n)$ 为卷积核， $y(n)$ 为卷积结果， n 为卷积核位移的量。将卷积层输出的结果作非线性的映射（保留特征，去除一些数据中的冗余），需要卷积层激活函数，本文的卷积层激活函数选取为 ReLU 函数^[11]，计算公式如式（2）：

$$f(x) = \max(0, x) \quad (2)$$

其中， $x > 0$ 时，该层的输出等于输入，无梯度耗散收敛快；当 $x \leq 0$ 时，该层的输出为 0，训练完成后为 0 的神经元越多，稀疏性越大，提取出来的特征就越具有代表性，泛化能力越强。

池化层则是降低特征维度，以此达到减小计算复杂度，避免过拟合的目的。池化方式一般有平均池化（mean pooling）和最大池化（max pooling）这两种，两者都伴随着原始图像维度的降低。最大池化是选取图像目标局部区域的最大值作为该区域池化后的值，对提取纹理特征更好。计算公式如式（3）：

$$y_{ij} = \max_{(i,j) \in \Omega} x_{ij} \quad (3)$$

其中， x_{ij} 为邻域 Ω 内的 i 行、 j 列的函数值； Ω 表示以 x_{ij} 为中心某一定值的邻域。图 1 为卷积核尺寸 2×2 、步长为 2 的池化窗口对原始图像的最大池化过程，左侧输入为原始图像的像素表示，右侧输出为最大池化后的效果。




图 1 最大池化示意图

Figure 1 Maximum pooling schematic

全连接层，即输出层的神经元和输入层的每个神经元都相连接，其本质就是一个分类器，可以让整个网络使用基于梯度的学习方法来进行全局训练，比如 softmax、RBF 网络、一层或两层的全连接神经网络等分类算法，即使不可微的分类器（比如 svm）也可以使用。其中 Softmax 分类器由于其复杂度低且分类效果好，在神经网络中广泛应用。

考虑对模型速度和效果的影响^[12]，本文从 CNN 的卷积核、层的效果及层数入手，将 CNN 的卷积核修改为 3×3 、在全连接层后加入 dropout 层和在网络模型第五层后增加两层卷积层。

3 改进 AlexNet 模型

3.1 AlexNet 模型

整个 AlexNet 模型有 8 个需要训练参数的层（不包括池化层和 LRN 层），前 5 层为卷积层，后 3 层为全连接层。用于交通标志识别的 AlexNet 最后一层是有 43 类输出的，这是由分类任务决定的，Softmax 输出层用作分类，而最大池化层出现在前两个卷积层及最后一个卷积层后。AlexNet 网络的基本结构如图 2 所示。




图 2 AlexNet 网络的基本结构

Figure 2 The basic structure of the AlexNet network

3.2 网络模型改进

在卷积神经网络训练过程中，有时由于数据集的大小和过度训练，会出现训练的模型在训练数据集中拟合程度很好，但在测试数据集中拟合效果较差的现象即过拟合。为了预防和减少过拟合，在全连接层后加入 dropout^[13] 的优化方案，dropout 是在每层神经元单元训练开始时，随机的删除一定比例（一般设为 0.5）的隐藏层神经元，保持输入层与输出层的个数不改变。然后按照 BP 学习算法对 CNN 中的参数进行学习更新（虚线连接的单元不更新），这样一次迭代更新便完成，下一次迭代中同样随机选择删除一些神经元，直至训练结束。如图 3 所示，图 3（a）为未使用 dropout 的三层神经网络，图 3（b）为使用 dropout 的三层神经网络。




Figure 3 Neural network contrast diagram

$$\begin{aligned} z_i^{(l+1)} &= w_i^{(l+1)} y^l + b_i^{(l+1)}, \\ y_i^{(l+1)} &= f(z_i^{(l+1)}). \end{aligned}$$
$$\begin{aligned} r_j^{(l)} &\sim \text{Bernoulli}(p), \\ \tilde{y}^{(l)} &= r^{(l)} * y^{(l)}, \\ z_i^{(l+1)} &= w_i^{(l+1)} \tilde{y}^l + b_i^{(l+1)}, \\ y_i^{(l+1)} &= f(z_i^{(l+1)}). \end{aligned}$$

如上所述,得到改进的 AlexNet 网络模型结构如图 4 所示,此时 AlexNet 网络模型的参数设置如表 1 所示。

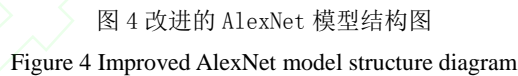


Table 1 Improved AlexNet network model setting

[illegible]

L9(Full)	1000	—	—	—	—	—	—	—	—	1000
L10(Softmax)	1000	—	—	—	—	—	—	—	—	44

4 实验与结果分析

4.1 实验数据

实验使用德国交通标志数据集 (German Traffic Sign Recognition Benchmark, GTSRB)^[14], 该数据集包含 43 类从德国真实交通环境中采集的交通标志, 其中训练集有 39029 幅, 测试集有 12630 幅, 总计为 51839 幅图像, 每幅图像只包含一个交通标志, 且数据集中包括大量低分辨率、不同光照强度、局部遮挡、视角倾斜、运动模糊等各种不利条件下的图像, 能够较真实且全面地反映现实情况、评价算法性能。由于本文使用的是卷积神经网络方法, 所有的图像都必须大小一致, 文献[15]把所有的图像都转化成 48×48 大小, 获得感兴趣区域。卷积神经网络方法具有很强的鲁棒性, 因此并没有使用具体的去噪方法进行去噪。

4.2 实验平台及流程

实验所用的计算机配置是 I5-7500 处理器, 主频 3.4GHz, 内存 16GB, Nvidia GeForce GT730 显卡, Ubuntu 16.04 版本的 Linux 操作系统, 深度学习框架为 caffe^[16], 软件编程环境为 Python 2.7。实验流程如图 5 所示。

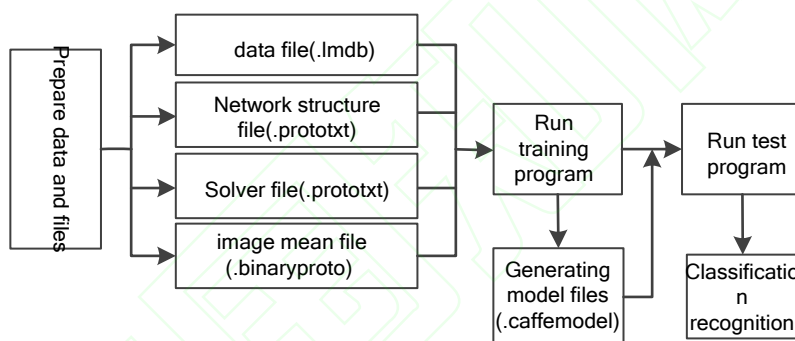


图 5 实验流程图

Figure 5 Experimental flow chart

4.3 实验结果及分析

为了验证使用 dropout 改进后的模型在交通标志识别上是否具有有良好的防止过拟合的效果, 首先将原 AlexNet 模型、改进后的模型 (无 dropout) 和改进后的模型 (有 dropout) 3 种模型进行实验对比。测试样本随机从测试集中选取 5000 幅, 对比从测试样本错误量、测试误差率两方面进行分析。

表 2 Dropout 对模型的影响

Table 2 The impact of Dropout on the model

Model	AlexNet model	Improved model(without dropout)	Improved model(withdropout)
Test sample error number	196	173	58
Test error rate	0.040	0.035	0.012

由表 2 可知, 改进后的模型 (有 dropout) 测试样本错误量最少同时测试误差率最小, 因此本文提出的改进后的模型使用 dropout 具有良好的防止过拟合作用。

在全连接层后均加入 dropout 层, 采用 AlexNet 模型、本文改进的模型分别进行两组实验, 求解文件参数为: 初始学习率设为 0.001, 防止过拟合权重衰减项为 0.0005, Momentum 为 0.9, gamma 为 0.1, 每训练 1000 次进行一次测试, 每训练 20 次在显示屏上显示一次。

采用 AlexNet 模型时最大迭代次数设为 10000 次；采用改进的模型时最大迭代次数也设为 10000 次，训练结束均可得到稳定的结果。

(1) 特征图可视化

图 6 为一张交通标志图像在本文改进方法所提模型中经过各个卷积层特征处理后的部分结果，展示 CNN 在各个阶段进行图像处理的情况。从图 6 可以看出，C1、C2 低层响应特征图关注图像纹理及轮廓这样的不同细节特征，像 C7 高维响应特征图就变得局部且稀疏，甚至无法通过肉眼辨别，用来滤除不相关的内容并提取出重要特征。





图 6 部分卷积层操作可视化

Figure 6 Visualization of the coiling layer operation

(2) 学习曲线可视化

在训练过程中，通过绘制 Accuracy 和 Loss 曲线能够较为直观清楚地观察到训练的动态过程。图 7 中 (a)、(b) 分别表示采用 AlexNet 模型和改进的模型这两组网络模型在训练过程中对应的 Accuracy 和 Loss 曲线。采用 AlexNet 模型时最大迭代次数设为 10000 次；采用改进的模型时最大迭代次数也设为 10000 次。由图 7 (b) 明显得出，两组模型 Loss 值不断下降直至当平稳，Accuracy 值不断上升达到平稳。图 7 (a) 中 AlexNet 模型的 Loss 值接近 0 且 Accuracy 值达到稳定状态时，网络迭代次数 iteration 在 8000 次以后。而图 7 (a) 中改进的模型当网络迭代次数 iteration 在 3000 至 7000 次时，Loss 值接近 0，Accuracy 值达到约 97%，网络达到稳定状态。



(a) Accuracy 曲线

(b) Loss 曲线

图 7 Accuracy 和 Loss 曲线对比图

Figure 7 Accuracy and Loss curve contrast diagram

(3) 算法分类能力分析

采用 AlexNet 模型、本文改进的模型就算法分类能力作比较分析，从表 3 可以看出，改

进的模型在参数消耗内存大幅减少的情况下，识别准确率还要高出约 1.3 个百分点。由此可见，本文对 AlexNet 模型进行的所有改进都是合理有效的。

表 3 算法分类能力分析

Table 3 Algorithm classification ability analysis

Algorithm	Training time(h)	Parameter consumption memory (MB)	Identifying each image time (ms)	Recognition accuracy (%)
Using AlexNet model	173	228.2	158	95.568
Using improved model	16	21	40	96.875

设定只采用改进条件 1 为对比模型 1，设定只采用改进条件 2 为对比模型 2。实验中求解文件参数设置一致：最大迭代次数均为 10000 次，初始学习率设为 0.001，防止过拟合权重衰减项为 0.0005，Momentum 为 0.9，gamma 为 0.1，每训练 1000 次进行一次测试，每训练 20 次在显示屏上显示一次。对比模型 1 的实验结果与改进模型做比较，对比模型 2 的实验结果与改进模型做比较，如表 4 所示。

表 4 算法对比分析

Table 4 Algorithm comparison and analysis

Algorithm	Training time(h)	Parameter consumption memory (MB)	Recognition accuracy(%)
Improved model	16	21	96.875
Contrast model 1	21	21.7	—
Contrast model 2	—	21.2	93.750

由表 4 可以看出，对比模型 1 只采用改进条件 1，压缩减少卷积层的学习参数总量，将所有卷积层的卷积核修改为 3×3 大小，代替原来的 11×11 和 5×5 卷积核，训练时间加快了，由 21h 减少到 16h。对比模型 2 只采用改进条件 2，在第五层后面增加两层卷积层，网络识别精度提高了，由 93.750% 提高到 96.875%。

为了客观对本文算法进行分析，基于相同的数据集将本文算法与其他交通标志的识别算法进行比较，表 5 列举了几种不同方法在 GTSRB 数据集的识别准确率与实时性的比较，可见针对交通标志这个识别目标，设计一种优秀的网络模型，提取有效的特征层信息，其识别准确率会大大提升。

表 5 不同方法在 GTSRB 数据集识别结果对比

Table 5 Comparison of different methods in GTSRB dataset recognition results

Algorithm	Classification time(ms)	Accuracy rate (%)
HOG+SVM algorithm of literature[17]	176	95.68
ANN	—	89.63
Random Forests	—	96.14
Improved model algorithm	40	96.875
The algorithm of literature[1]	275	99.01
The algorithm of literature[6]	152	98.57

由表 5 可知，本文改进模型算法比 HOG+SVM 算法、ANN 和随机森林算法的识别准确率都高，虽然本文改进模型算法比文献[1]和文献[6]的识别准确率低些，但是分类时间明显比文献[1]和文献[6]的分类时间少很多，实时性和识别准确率均能满足交通标志识别的要求。

(4) 实际环境条件因素下的识别

随机选取在实际行车环境下的 30 幅运动过程中模糊的图像，51 幅受背景干扰的图像，30 幅受光照（天气）条件影响图像和 30 幅存在拍摄角度的图像，作为实际环境条件因素下的识别。此时，直接调用训练 8000 次保存的 AlexNet 模型、训练 3000 至 7000 次保存的改

进的模型文件，统计测试样本数量和正确识别出来的数量，并计算准确率。测试结果如表 6（a）、（b）所示。

表 6（a）实际环境条件下 AlexNet 模型的识别情况

Table 6 (a) Identification of AlexNet models under real environmental conditions

Type	Test sample number	Correct recognition number of AlexNet model	Recognition accuracy rate of AlexNet model (%)
Motion blur	30	22	73.3
Background interference	51	43	84.3
Light (weather)	30	25	83.3
Shooting angle	30	26	86.6

表 6（b）实际环境条件下改进模型的识别情况

Table 6 (b) Identification of Improved models under real environmental conditions

Type	Test sample number	Correct recognition number of Improved model	Recognition accuracy rate of Improved model (%)
Motion blur	30	23	76.6
Background interference	51	45	88.2
Light (weather)	30	27	90.0
Shooting angle	30	28	93.3

从表 6 测试结果可以看出，四种实际环境条件因素下的改进的模型识别准确率都达到了较高的水平，说明本文采用的改进模型具有良好的分类识别能力。但是在各种环境条件下识别过程中仍存在分类错误的个例，这主要是由于图像受实际环境因素中多种因素综合影响，图像受损比较严重。

5 结论

本文设计并实现了改进深度卷积神经网络 AlexNet 的网络模型及结构，给出了算法模型参数，通过多次实验验证了本文算法参数设计的合理性，应用于交通标志识别取得了良好的效果，在 GTSRB 数据集上得到了 96.875% 的识别准确率、分类识别每幅图像 40 毫秒的识别速度。通过与 AlexNet 模型对比，在参数总量大幅减少的情况下，识别准确率还要高出 1.3 个百分点，验证了本文算法具有一定的先进性；通过在四种实际环境条件因素下的识别，验证了本文算法具有良好的鲁棒性，但本文算法在识别受损严重的图像方面仍需深入研究。

参考文献

[1] Xu Y, Wei Z Y. An improved traffic sign image recognition algorithm [J].Laser and Optoelectronics Progress, 2017,54 (02): 124-131.
徐岩, 韦镇余. 一种改进的交通标志图像识别算法 [J]. 激光与光电子学进展, 2017, 54(02): 124-131.

[2] Zhang S F, Zhu T. A traffic sign detection and recognition method based on HDR technology [J/OL]. Laser and Optoelectronics Exhibition: 1-11[2018-05-24].
张淑芳, 朱彤. 一种基于 HDR 技术的交通标志牌检测和识别方法 [J/OL]. 激光与光电子学进展: 1-11[2018-05-24].

[3] LUO H, YANG Y, TONG B, et al. Traffic sign recognition using a multi-task convolutional neural network [J]. IEEE Transactions on Intelligent Transportation Systems, 2017, PP (99) : 1-12.

[4] Zhong X M. Research on traffic sign recognition algorithm based on fast regional convolution neural network [A]. China Automotive Engineering Society. 2016 China Automotive Engineering

Society annual meeting paper [C]. China Automotive Engineering Society: 2016:4.

[5] Tan T Z, Lu J B, Wen J W, et al. Traffic sign recognition using convolution neural network and RPN [J/OL]. Computer engineering and application: 1-8[2018-05-08].

谭台哲,卢剑彪,温捷文,等.应用卷积神经网络与 RPN 的交通标志识别[J/OL].计算机工程与应用:1-8[2018-05-08].

[6] Xu Z, Feng C H. Improved scale dependent pool model for traffic image recognition [J]. computer applications, 2018,38 (03): 671-676.

徐喆,冯长华.用于交通图像识别的改进尺度依赖池化模型[J].计算机应用,2018,38(03):671-676.

[7] Dang Y, Zhang J X, Deng C Z, et al. Classification and evaluation of remote sensing image surface cover based on deep learning AlexNet [J]. Journal of geoinformation science, 2017,19(11):1530-1537.

党宇,张继贤,邓喀中,等.基于深度学习 AlexNet 的遥感影像地表覆盖分类评价研究[J].地球信息科学学报,2017,19(11):1530-1537.

[8] Lv H M, Zhao D, Chi X B. Early diagnosis of alzheimer's disease based on intensive learning of AlexNet [J]. Computer science, 2017,44(S1):50-60.

吕鸿蒙,赵地,迟学斌.基于增强 AlexNet 的深度学习阿尔茨海默病的早期诊断[J].计算机科学,2017,44(S1):50-60.

[9] Zhang Y M, Chang F L, Li N J, et al. Modified AlexNet for Dense Crowd Counting[J]. Proceedings of the 2nd International Conference on Computer Engineering, Information Science and Internet Technology(CII 2017)[C].

[10] Chen Q J, Li Y, Chai Y Z. A multi focus image fusion algorithm based on deep learning [J/OL]. Progress in laser and Optoelectronics: 1-14[2018-06-12].

陈清江,李毅,柴昱洲.一种基于深度学习的多聚焦图像融合算法[J/OL].激光与光电子学进展:1-14[2018-06-12].

[11] Li J N, Zhang B H. Feature matching fusion combined with improved convolutional neural network for face recognition [J/OL]. Laser and Optoelectronics Progress: 1-15[2018-06-12].

李佳妮,张宝华.特征匹配融合结合改进卷积神经网络的人脸识别[J/OL].激光与光电子学进展:1-15[2018-06-12].

[12] Xiao J S, Liu E Y, Zhu L, et al. Improved image super-resolution algorithm based on convolution neural network [J]. Acta optica Sinica, 2017,37 (03): 103-111.

肖进胜,刘恩雨,朱力,等.改进的基于卷积神经网络的图像超分辨率算法[J].光学学报,2017,37(03):103-111.

[13] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptating of feature detectors[J]. Computer Science, 2012,3(4):212-223.

[14] Stallkamp J, Schlipsing M, Salmen J, et al. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition[J]. Neural Networks, 2012,32(2):323-332.

[15] Liu Z W, Zhao X M, Li Q, et al. The method of identification of traffic signs based on graph model and convolution neural network [J]. Journal of transport engineering, 2016,16 (05): 122-131.

刘占文,赵祥模,李强,等.基于图模型与卷积神经网络的交通标志识别方法[J].交通运输工程学报,2016,16(05):122-131.

[16] OU X F, XIANG C Q, GUO L Y, et al. Research on license plate character recognition algorithm based on Caffe deep learning framework [J]. Journal of Sichuan University (NATURAL

SCIENCE EDITION), 2017,54 (05): 971-977.

欧先锋,向灿群,郭龙源,等.基于 Caffe 深度学习框架的车牌数字字符识别算法研究[J].四川大学学报(自然科学版),2017,54(05):971-977.

[17] RUTA A,LI Y,LIU X. Real-time traffic sign recognition from video by class-specific discriminative features[J].Pattern Recognition,2010,43(1) : 416-430.



网络首发:

标题: 基于改进深度卷积神经网络的交通标志识别

作者: 马永杰, 李雪燕, 宋晓凤

收稿日期: 2018-05-25

录用日期: 2018-07-12

DOI: 10.3788/lop55.121009

引用格式:

马永杰, 李雪燕, 宋晓凤. 基于改进深度卷积神经网络的交通标志识别[J]. 激光与光电子学进展, 2018, 55(12): 121009.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文:

基于帧间信息提取的单幅红外图像深度估计

顾婷婷 赵海涛 孙韶媛

华东理工大学信息科学与工程学院, 上海 200237

激光与光电子学进展, 2018, 55(6): 061010

二维和三维卷积神经网络相结合的CT图像肺结节检测方法

苗光 李朝锋

江南大学物联网工程学院, 江苏 无锡 214122

激光与光电子学进展, 2018, 55(5): 051006

基于X射线的复杂结构件内部零件装配正确性检测

吴桐 陈平

中北大学信息与通信工程学院, 山西 太原 030051

激光与光电子学进展, 2018, 55(4): 041012

基于深度残差学习的乘性噪声去噪方法

张明 吕晓琪 吴凉 喻大华

内蒙古科技大学信息工程学院, 内蒙古 包头 014010

激光与光电子学进展, 2018, 55(3): 031004

基于多特征融合的卷积神经网络图像去雾算法

徐岩 孙美双

天津大学电气自动化与信息工程学院, 天津 300072

激光与光电子学进展, 2018, 55(3): 031012