

应用卷积神经网络与RPN的交通标志识别

谭台哲^{1,2}, 卢剑彪¹, 温捷文¹, 李楚宏¹, 凌伟林¹

TAN Taizhe^{1,2}, LU Jianbiao¹, WEN Jiewen¹, LI Chuhong¹, LING Weilin¹

1. 广东工业大学 计算机学院, 广州 510006

2. 广东工业大学(河源)协同创新研究院, 广东 河源 517000

1. College of Computer Science and Technology, Guangdong University of Technology, Guangzhou 510006, China

2. Synergy Innovation Institute of Guangdong University of Technology, Heyuan, Guangdong 517000, China

TAN Taizhe, LU Jianbiao, WEN Jiewen, et al. Traffic signs recognition applying with convolutional neural network and RPN. Computer Engineering and Applications, 2018, 54(21): 251-256.

Abstract: In the intelligent transportation system, traffic sign recognition is required to have good robustness and real-time performance. In the actual traffic environment may be due to road signs fuzzy, light intensity, scale size, complex background and so on, resulting in traffic recognition accuracy is very low. In this paper, to solve these problems, having improve uses depth learning method to design convolutional neural networks, through the multi-level processing of convolution and pool sampling, combining the RPN network structure of the target detection method, the candidate regions of the image are extracted, so that the candidate regions are extracted, finally using connection network to return to the characteristics of figure, access to the location of the object detection and recognition. The experimental results show that the method can effectively improve the detection accuracy and computational efficiency, reduces the error rate, for traffic sign detection under adverse factors such as illumination, rotation has good stability and accuracy, effectively improves the efficiency of traffic sign recognition, has good generalization ability and adaptability, and meets the requirement of real-time.

Key words: traffic sign detection; real-time; Region Proposal Network(RPN); intelligent transportation

摘 要: 在智能交通系统中要求交通标志识别具有良好的鲁棒性、实时性,并且实际交通环境中可能因路标模糊、光照强弱、尺度大小、复杂背景等因素的问题,导致交通标志识别准确率很低。针对上述问题,提出了利用深度学习方法设计卷积神经网络,并通过卷积和池采样的多层处理,结合目标检测方法中的RPN网络结构,以提取图像的候选区域,从而对候选区域进行特征提取,最后利用全连接网络实现对特征图进行回归处理,获取检测目标的位置及识别。实验结果表明,该方法能有效地提高检测精度和计算效率,降低错误率,对于光照、旋转等不良因素下交通标志检测具有较好的稳定性和准确性,有效地提高了交通标志识别效率,具有良好的泛化能力和适应性,且满足一定的实时性的要求。

关键词: 交通标志检测;实时;区域生成网络(RPN);智能交通

文献标志码:A **中图分类号:** TN911.73-34; TP391.41 doi: 10.3778/j.issn.1002-8331.1707-0355

1 引言

随着无人驾驶技术的快速发展,极大地加速了智能交通系统与先进辅助驾驶系统的研究进程。交通标志的自动检测与识别^[1],不仅可以给驾驶员或无人车提供

实时的道路标志信息,而且是研究智能交通至为重要的内容。在日常生活中,交通标志一般设计成特定颜色和几何形状,这非常方便研究。本文检测的交通标志主要为三类:警告标志、禁令标志和指示标志,这三类也是最

作者简介: 谭台哲(1970—),男,博士,副教授,主要研究领域为计算机视觉、生物特征识别、机器学习和大数据处理;卢剑彪(1990—),通讯作者,男,硕士研究生,主要研究方向为目标检测、生物特征识别;温捷文(1992—),硕士研究生,主要研究方向为计算机视觉、图像处理;李楚宏(1992—),男,硕士研究生,主要研究方向为图像处理、机器学习;凌伟林(1992—),男,硕士研究生,主要研究方向为计算机视觉、机器学习。

收稿日期: 2017-07-21 **修回日期:** 2017-09-08 **文章编号:** 1002-8331(2018)21-0251-06

CNKI网络出版: 2018-03-05, <http://kns.cnki.net/kcms/detail/11.2127.TP.20180305.1302.022.html>

为常见的交通标志。图1列举了部分我国的交通标志^[2],它们都有着特定的颜色和几何形状用以区分其他周围物体,以达到提醒驾驶员或行人的目的。



图1 部分我国交通标志三大类实例

近年来,深度学习的方法在图像分类、目标检测和语音识别方面展现出极好的性能。深度卷积神经网络在实际场景中对于不同尺寸目标检测与分类具有强大的优势。在智能交通系统中,主要包含两个基本环节:对自然场景图像中的交通标志进行检测^[3],包括交通标志的定位、提取及必要的预处理;对检测到的交通标志进行识别,包括对交通标志的特征提取和分类。

自从德国交通标志检测基准(German Traffic Sign Detection Benchmark, GTSDb)^[4]和德国交通标志识别基准(German Traffic Sign Recognition Benchmark, GTSRB)^[5]发行以来,许多研究人员提出了大量关于改进交通标志检测与分类^[6]的方法,这些方法在GTSDb和GTSRB基准上达到了很高的准确度。然而,这个基准数据集并不能完全代表我国实际交通场景。在自然场景中,交通标志在图像中往往占据很小的尺寸,如一张1360×800像素的图像,交通标志尺寸大小为64×64像素,占据整张图像不到0.38%。这种情况下所获得的候选区域要远小于一般目标检测中使用PASCAL VOC基准和ImageNet ILSVRC基准所获取的候选区域。因此,选择交通标志基准是由腾讯街景全景(Tencent Street View panoramas, TSV)拍摄的高分辨率图像10000张组成。

2 深度学习在交通标志应用

在交通标示识别^[7]过程中,主要包含为两个方面:检测与分类。

2.1 深度学习方法中目标检测

自Hinton等人^[8]在ImageNet比赛中率先使用卷积神经网络算法用于进行目标检测及图像分类获得冠军后,深度学习算法重新引起广泛关注并得到快速发展。在Sermanet等人发表的Overfeat^[9]论文中,他们研究发现对目标物体进行检测时,对整张图像进行滑动窗口处理效率更高,中间处理的计算结果可以在重叠区域(IoU)重复使用,并且在这个网络结构中,利用这个结构标签来确定目标对象的边界框。

针对滑动窗口存在的问题,Girshick^[10]提出了一种

利用候选区域(Region proposal)和卷积神经网络代替传统目标检测使用滑动窗口和手工设计的策略,设计了R-CNN框架。然而,这个框架也存在训练耗时,占用磁盘空间大,运用选择性搜索算法(Selective Search, SS)^[11]提取候选区域,导致生成候选区域速度慢问题。针对速度慢的问题,SPP-NET^[12]论文中提出了对整张图像计算共享特征区域,将这些大小不同的特征向量映射到相同维度上,从而只需对图像提取一次卷积特征。虽然,这使得SPP-NET方法相比于R-CNN方法大大加快了目标检测的速度,但是依然存在着训练分为多个阶段,步骤繁琐以及在微调网络时固定了卷积层,只对全连接层进行微调,而很多时候需要对卷积层进行微调。针对这些问题,Girshick又提出了一个精简且快速的Fast R-CNN^[13]目标检测方法,在Fast R-CNN网络结构中,直接使用softmax层替代SVM分类,同时利用多任务损失函数作边框回归。除去候选区域提取消耗的时间,在这个网络结构中,对图像进行特征分类只需要0.32 s。为降低提取候选区域消耗的时间,Ren等人在Faster R-CNN^[14]论文中提出了候选区域网络(RPN),使用训练好的RPN网络,给定测试图像,可以直接得到边缘回归后的候选区域,并且目标检测速度达到5 frame/s。虽然,Faster R-CNN将候选区域和卷积神经网络分类融合到一起,使用端到端的网络进行目标检测,但是仍然达不到实时的目标检测要求。

为了在速度上满足实时性要求,Redmon等人在YOLO^[15]论文中使用回归思想,对给定的输入图像,直接在图像的多个位置回归出该位置的目标边框及类别,大大加快了检测速度,使得YOLO处理图像达到45 frame/s。然而,在YOLO中去除了候选区域机制,导致检测精度并不是很高。基于这个问题,在SSD^[16]论文中结合YOLO回归思想和Faster R-CNN的anchor机制,使用全图各个位置多尺度区域特征进行回归,检测速度达到了58 frame/s。

综上所述,这些目标检测的方法主要采用的基准数据集是PASCAL VOC和ImageNet ILSVRC,在这些基准数据集图像中,检测目标都在图像的较大尺度,而自然场景图像中交通标志往往都占据极小比例。

2.2 交通标志的分类

交通标志分类的目的是为了将检测到的交通标志归入到其特定的子类,如警告、禁令、指示。目前,较好的方法是采用卷积神经网络对交通标志进行检测,进而对检测到的交通标志进行识别分类。在Stallkamp等人发表的交通识别基准和人类与计算机:利用机器学习算法对交通标志识别^[17]这两篇论文中,实验中充分论证了卷积神经网络在交通标志分类上的表现要远好于人类。在Lecun等人发表的使用多尺度卷积网络进行交通标志识别^[18]论文中,使用层跳过连接,利用多尺度特




图2 多尺度网络结构

征进行交通标志分类,在第一阶段GTSRB竞赛中的表现也要远好于人。在Ciresan等人^[19],使用多列深度卷积神经网络(Multi-Column Deep Neural Network, MCDNN)进行交通标志分类也远好于人并赢得第二阶段GTSRB竞赛冠军。之后,Wang等人利用多层次支持向量机^[20]方法实现了比MCDNN稍微更好的效果,检测速度达到40 frame/s。Jin等人^[21]发表的论文中,提出利用一个铰链随机梯度下降损失函数(hinge loss stochastic gradient descent)去训练卷积神经网络并在GTSRB测试集上识别率达到了99.65%。近来,Yoon等人^[22]提出通过使用卷积神经网络和卷积神经网络的补偿错误率,并利用相邻两帧图像之间时间相关性,而不是利用传统的更多层次的卷积神经网络结构及时间分类误差补偿(Temporal Classification Error Compensation, TCEC)。通过该方法,与同一层网络结构相比复杂性减少了50%,交通标志识别错误率提高了约3%。

3 交通标志数据集基准

由于现行国内还没有公开统一的交通标志数据集基准,许多研究组织都是使用GTSDB作为交通标志检测基准和GTSRB作为交通标志识别分类基准。在本文中,采用的基准是TSV使用高清摄像头拍摄我国街景道路图像,其分辨率达到了2 048×2 048,要远高于GTSDB和GTSRB基准数据集图像1 380×800分辨率。TSV采集的图像包含国内约300余城市街道或郊区,具有较强的普适性,并在连续拍摄到自然场景下的原始交通全景图像之后,对其进行简单的图像处理。经过这样处理,连续拍摄的交通图像有着一定的相关性,部分遮挡或模糊的交通标志可以通过它们之前或之后图像加以构建识别准确分类。在实验过程中,将数据集基准中输入图像进行归一化为640×480。

4 设计方法

4.1 网络结构模型

Huval等人^[23]发表的使用深度学习方法评估在高速公路驾驶论文中,利用卷积神经网络方法对在高速公路上行驶的车辆进行检测,采用OverFeat带边界回归的网络结构框架,包含全卷积层及将最后一层分为像素层(pixels layer)和边界框层。他们设计的网络结构用于对高速公路上的车辆进行检测取得很好的效果。然而,

他们设计的网络结构用于对高速公路上的车辆进行检测取得很好的效果。然而,他们设计的网络结构并不适合用于小目标物体的检测。综合Haval等人设计网络结构及现行主流的Faster R-CNN目标检测算法,采用图2网络结构框架,在这个网络结构中总共包含七层卷积层。然而,在Simony等人^[24]和Szegedy等人^[25]发表的论文中一致认为,深卷积网络的网络结构更优,功能更加强大,表现出来的效果也更好。假设网络结构更早地进行分支让其各自进行深卷积运算,虽然这样看上去能够获得更好效果,但是极大地增加了数据集的训练时间及对GPU内存的大量消耗。因此,综合速度和准确度考虑,在网络结构中共享计算过程的中间值并在第六层后开始分支出来。在最后一层中含有三个分支,分别是bbox层用于边界回归, pixel层用于区别检测的目标和背景, label层表示的是一个 n 维分类概率向量 p 。

为了提取质量较好的候选区域,在网络结构框架中,采用了Faster R-CNN算法中的RPN机制来提取候选区域,其结构模型图3。RPN主要使用卷积神经网络直接产生候选区域,并只需在最后的卷积层上滑动一遍。图3在RPN网络结构中对给定输入的一张图像,经过卷积操作得到最后一层的卷积特征图,并在这个特征图上使用3×3卷积核与特征图进行卷积,最后,得到一个256维的特征图。

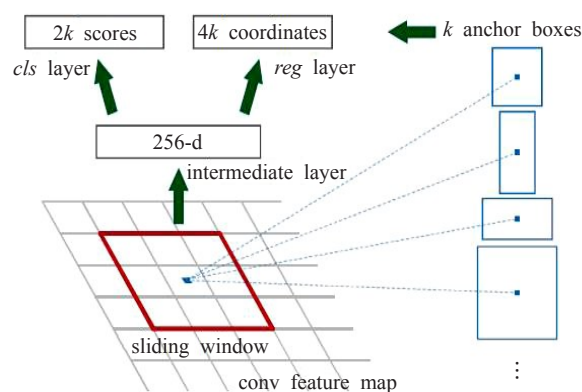


图3 RPN网络结构图

在最后一层 conv8-bbox 对候选区域进行回归定位。参照文献[10]采用四个坐标,表示如下:

$$t_x = (x - x_a) / w_a \quad (1)$$

$$t_y = (y - y_a) / h_a \quad (2)$$

$$t_w = \ln(w / w_a) \quad (3)$$

$$t_h = \text{lb}(h/h_a) \quad (4)$$

$$t_x^* = (x^* - x_a)/w_a \quad (5)$$

$$t_y^* = (y^* - y_a)/h_a \quad (6)$$

$$t_w^* = \text{lb}(w^*/w_a) \quad (7)$$

$$t_h^* = \text{lb}(h^*/h_a) \quad (8)$$

其中, x, y, w, h 为预测包围框的中心坐标、宽、高; x_a, y_a, w_a, h_a 为 anchor box 的中心坐标、宽、高; (t_x, t_y) 为到 anchor box 平移量, (t_w, t_h) 为到 anchor box 尺度缩放移量, (t_x^*, t_y^*) 为到标定的 Ground Truth 尺度缩放量。在 conv8-label 层中, 对每一个感兴趣区域 (Region Of Interest, ROI) 输出的离散概率分布:

$$p_i = (p_0, p_1, \dots, p_n) \quad (9)$$

则, 对一个图像损失函数定义为:

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{\text{label}}} \sum_i L_{\text{label}}(p_i, p_i^*) + \lambda \frac{1}{N_{\text{bbox}}} \sum_i p_i^* L_{\text{bbox}}(t_i, t_i^*) \quad (10)$$

其中, i 表示一个 mini-batch 中 anchor 索引, p_i 是第 i 个 anchor 的交通标志预测概率。若 anchor 为正, 则 GT 的 p_i^* 为 1; 若 anchor 为负, 则 GT 的 p_i^* 为 0。 t_i 表示预测包围框的 4 个参数化坐标向量, t_i^* 表示标定的 GT 包围框的坐标向量。 $N_{\text{label}}, N_{\text{bbox}}$ 表示 ROI 总数。分类损失 L_{label} 是由两个类别, 是含交通标志和不含交通标志的对数损失得到:

$$L_{\text{label}}(p_i, p_i^*) = -\text{lb}[p_i^* p_i + (1 - p_i^*)(1 - p_i)] \quad (11)$$

对于回归损失函数 L_{bbox} 为:

$$L_{\text{bbox}}(t_i, t_i^*) = R(x)(t_i - t_i^*) \quad (12)$$

其中, $R(x)$ 是^[11]定义的鲁棒损失函数:

$$R(x) = \begin{cases} 0.5x^2, & |x| < 1 \\ |x| - 0.5, & |x| \geq 1 \end{cases} \quad (13)$$

4.2 训练数据集

实验中的数据集基准是从 TSV 中取出的 10 000 张交通图像, 其中 9 000 张用于训练, 1 000 张用于测试。由于不同种类的交通标识数量并不完全相同。为了从训练卷积网络中获取更好的效果, 选择对训练过程中的数据集样本采用数据增强技术, 主要通过对数据集样本进行随机旋转 ($-10^\circ \sim 10^\circ$), 尺度缩放在 (20~200) 范围及对数据集样本在 x 和 y 轴上进行适量的平移 ($-5\% \sim 5\%$)。经过这种方式处理, 将训练的样本数据扩大了几十倍, 提高了对于小目标特征的提取性能, 并有效地解决了因天气、模糊、障碍物阻挡等因素对交通标志特征提取造成影响的问题。

5 实验结果与分析

在深度学习中, 为了获得比较好的效果通常需要有

大量的数据集样本进行训练提取特征。正是利用深度学习这个特性。在本论文中, 采用的数据集是通过连续拍摄高分辨率图像, 每帧图像前后之间具有一定的关联性, 并且在对数据集进行训练前, 对数据集进行了旋转、平移、尺度变换等处理操作, 这样在获得大量训练样本的同时也有效地避免部分样本因路标模糊、光照等因素的影响。

实验中, 数据集基准主要包含了我国道路交通标志的警告标志、禁令标志、指示标志这三大类。在图 1 中列举了部分我国的交通标志, 并在网络配置参数文件中设定好 40 个包含这三大类的类型交通标志名, 其中, 警告标志用 W_表示, 如: W_Traffic circle; 禁令标志用 P_表示, 如: P_No-horn; 指示标志用 M_表示, 如: M_Packing space。

在检测阶段, 主要工作集中于提取目标候选区域^[26], 并对提取到的候选区域用红色方框标注出来。目前, 比较流行的提取目标候选区域的方法有 Selective Search、Edge Boxes、Multiscale Combinatorial Grouping 等, 这些方法对于较大目标候选区域的提取效果比较好。在本文中, 选择了其中一种提取候选区域的方法, 选择搜索算法 (Selective Search, SS) 与本文的方法作为实验对比。

实验过程中, 因不同类的交通标志具有不同的几何图案 (三角形、方形、圆形), 导致尺度大小不一以及因拍摄角度或拍摄距离的远近等因素, 造成交通标志在图像中所占据的比例大小也不尽相同。因此, 根据交通标志在图像中所占据像素大致大小划分为三个区间: 占据面积最小交通标识 ($0 < \text{面积} < 48 \text{ 像素} \times 48 \text{ 像素}$), 占据面积中等交通标识 ($48 \text{ 像素} \times 48 \text{ 像素} < \text{面积} < 128 \text{ 像素} \times 128 \text{ 像素}$), 占据最大面积交通标识 ($48 \text{ 像素} \times 48 \text{ 像素} < \text{面积} < 128 \text{ 像素} \times 128 \text{ 像素}$), 占据最大面积交通标识 ($\text{面积} > 128 \text{ 像素} \times 128 \text{ 像素}$)。分别做了三组实验, 图 4 为实验结果。此外, 为了验证本文的方法是否能很好解决路标模糊、光照等因素的问题。又另外选取了 1 000 张均包含清晰的交通标志街景图像组成的测试集与包含上述因素的样本测试集进行实验对比, 得到表 1 结果。

在图 4 中, 横坐标表示交通标志候选区域数量级变化, 纵坐标回收率设定以 Jaccard 相对系数 0.5 以上为基准的有效候选区域。从图 4 中可以看出, 训练的检测卷积网络最好时回收率达到了 95.3% 左右。

在对交通标志进行分类^[27]阶段, 设定好为每张图像生成的 10 000 个候选区域。采用深度学习方法中的 Faster R-CNN 目标检测算法与本文的方法进行对比测试, 同样依照上述划分的情况分别进行了三组测试实验, 图 5 为 Faster R-CNN 和本文的方法实验对比结果。从图 5 中, 可以看出, 对检测的交通标志在图像中占比越小, 本文的方法在性能上要优于 Faster R-CNN, 这也




图4 交通标识在Selective Search(SS)和本文方法在不同尺度下提取候选区域结果

表1 包含高清晰交通标志图像所得到的部分交通标志识别列举结果

测试项	W_Danger	W_Crossroads	W-Tunnel	P_No stopping	P_Stop	M_Packing space	M_Cycle track
本文方法召回率	0.821	0.773	0.538	0.910	0.942	0.973	0.889
本文方法准确率	0.899	0.779	0.681	0.933	0.942	0.998	0.928




图5 Faster R-CNN和本文的方法对不同尺度的交通标识分类的结果

表2 使用Faster R-CNN和本文的方法得到的部分交通标志识别列举结果

测试项	W_Dange	W_Crossroads	W-Tunnel	P_No stopping	P_Stop	M_Packing space	M_Cycle track
Faster R-CNN方法召回率	0.717	0.606	0.483	0.763	0.820	0.813	0.782
Faster R-CNN方法准确率	0.790	0.581	0.395	0.837	0.876	0.925	0.694
本文方法召回率	0.820	0.769	0.540	0.912	0.945	0.970	0.892
本文方法准确率	0.905	0.781	0.684	0.931	0.940	1.000	0.928

间接说明了Faster R-CNN方法适用于检测^[28]在图像中占比比较大目标物体。表1表示的是,另外选取1 000张清晰的高分辨率街景图像实验所获得的结果。表2表示的是实验过程中使用Faster R-CNN和本文的方法得到部分交通标志的召回率和识别准确率列举结果。表3表示的是,在本文的实验环境下,分别用Faster R-CNN和本文的方法对不同尺度的交通标志的平均准确率和以Jaccard相对系数0.5以上为基准的有效候选区域的平均召回率得到的实验数据。结合表1和表2,可以看到实验结果所获得的召回率和准确率相差不大。表4,表5表示的是单独考察bbox层和pixel层对于召回率和准确率影响结果。Label层主要是对于检测到交通标志之后起到分类作用,并不会对于召回率和准确率造成影响。结合表3、表4及表5,可以看到,如果在实验过程中,如果不提供前景背景判定,召回率上升,但准确率却明显下降。造成这个现象的主要原因是因为在城市街道等场景中,容易出现大量的在几何形状和颜色上与

交通标志类似的干扰物,而又因为缺乏前景背景判定,导致大量的干扰物也被认为是目标区域。图6为本文实验最终检测到交通标志并识别结果。

表3 Faster R-CNN和本文方法下的结果

测试项	(0,48]	(48,128]	(128,400]
Faster R-CNN方法召回率	0.217	0.726	0.843
Faster R-CNN方法准确率	0.481	0.599	0.638
本文方法召回率	0.864	0.953	0.938
本文方法准确率	0.765	0.932	0.907

表4 只有bbox层分支结果

测试项	(0,48]	(48,128]	(128,400]
本文方法召回率	0.683	0.792	0.811
本文方法准确率	0.457	0.732	0.625

表5 只有pixel层分支结果

测试项	(0,48]	(48,128]	(128,400]
本文方法召回率	0.714	0.867	0.836
本文方法准确率	0.407	0.483	0.441



图6 交通标志识别结果

6 结束语

RPN网络结构能够很好提取到高质量的候选区域,对于提高交通标志的检测性能起到至关重要的作用。在实验过程中,充分考虑了我国交通标志设计的特点,将交通标志在图像中占比分为三个区间的尺度分别进行检测,并且采用的数据集基准图像为我国实际路况。在交通标志检测过程中,利用RPN网络结构提取到候选区域,对提取到的特征,利用bbox层回归处理对其进行定位,最后,通过Label层分类概率向量确定其属于警告、禁止、指示中的哪一类。在本文中,只利用了交通标志的尺度信息,忽略了交通标志的颜色信息。为此,下一步,准备将交通标志的颜色信息结合起来,并尝试使用一些更加有效的目标检测方法,同时优化网络结构,进一步提升计算效率及准确率,以便获得更好的实时性。

参考文献:

- [1] Gao S, Zhang Y. The automatic detection and recognition of the traffic sign[C]//International Conference on Virtual Reality and Visualization, 2017.
- [2] Chinese traffic sign template, how published[EB/OL]. [2017-03]. <http://www.bjjtgl.gov.cn/jgj/jgbz/index.html>.
- [3] 王永平, 史美萍, 吴涛. 快速鲁棒的交通标志检测方法[J]. 计算机工程与应用, 2010, 46(32): 163-165.
- [4] Houben S, Stallkamp J, Salmen J, et al. Detection of traffic signs in real-world images: the German traffic sign detection benchmark[C]//International Joint Conference on Neural Networks, 2014: 1-8.
- [5] Namor A F D D, Shehab M, Khalife R, et al. The German traffic sign recognition benchmark: a multi-class classification competition[C]//International Joint Conference on Neural Networks, 2011: 1453-1460.
- [6] Mogelmose A, Trivedi M M, Moeslund T B. Vision-based traffic sign detection and analysis for intelligent driver assistance systems: perspectives and survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2012, 13(4): 1484-1497.
- [7] 戈侠, 于凤芹, 陈莹. 基于分块自适应融合特征的交通标志识别[J]. 计算机工程与应用, 2017, 53(3): 188-192.
- [8] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//International Conference on Neural Information Processing Systems, 2012: 1097-1105.
- [9] Sermanet P, Eigen D, Zhang X, et al. OverFeat: integrated recognition, localization and detection using convolutional networks[J]. Eprint Arxiv, 2013.
- [10] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.
- [11] Uijlings J R, Sande K E, Gevers T, et al. Selective search for object recognition[J]. International Journal of Computer Vision, 2013, 104(2): 154-171.
- [12] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2014, 37(9): 1904-1916.
- [13] Girshick R. Fast R-CNN[C]//IEEE International Conference on Computer Vision, 2015: 1440-1448.
- [14] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6): 1137.
- [15] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.
- [16] Liu W, Anguelov D, Erhan D, et al. SSD: single shot multibox detector[C]//European Conference on Computer Vision, 2016: 21-37.
- [17] Stallkamp J, Schlipsing M, Salmen J, et al. 2012 special issue: man vs. computer: benchmarking machine learning algorithms for traffic sign recognition[J]. Neural Networks the Official Journal of the International Neural Network Society, 2012, 32(2): 323-332.
- [18] Sermanet P, Lecun Y. Traffic sign recognition with multi-scale convolutional networks[C]//International Joint Conference on Neural Networks, 2011: 2809-2813.
- [19] Cireşan D, Meier U, Masci J, et al. Multi-column deep neural network for traffic sign classification[J]. Neural Networks, 2012, 32(1): 333-338.
- [20] Wang G, Ren G, Wu Z, et al. A hierarchical method for traffic sign classification with support vector machines[C]//International Joint Conference on Neural Networks, 2013: 1-6.
- [21] Jin J, Fu K, Zhang C. Traffic sign recognition with hinge loss trained convolutional neural networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(5): 1991-2000.

(下转第264页)

- 学学报(信息科学版), 2014, 32(2): 138-144.
- [2] 孙其博, 刘杰, 黎彝, 等. 物联网: 概念、架构与关键技术研究综述[J]. 北京邮电大学学报, 2010, 33(3): 1-9.
- [3] 李铭瑶, 薛新民. 云计算数据中心动力环境监控系统研究[J]. 信息技术与标准化, 2017(Z1): 57-60.
- [4] 单聪. 基于物联网的机房环境监控系统[D]. 南京: 南京邮电大学, 2014.
- [5] 何小利, 宋钰. 基于分布式技术的机房空调联网监控优化[J]. 计算机仿真, 2016, 33(3): 442-445.
- [6] 罗兰溪, 王良之, 王云飞, 等. 机房温湿度监控系统研究[J]. 中国新通信, 2017, 19(8): 18-19.
- [7] 袁慧, 张大伟, 张珂, 等. 面向电力机房监控的音视频融合检测方法研究[J]. 计算机工程, 2016, 42(12): 272-277.
- [8] 龚钢军, 孙毅, 蔡明明, 等. 面向智能电网的物联网架构与应用方案研究[J]. 电力系统保护与控制, 2011, 39(20): 52-58.
- [9] 中国工业和信息化部. 物联网总体框架与技术要求(YD/T2437-2012)[M]. 北京: 人民邮电出版社, 2013.
- [10] Kim S M, Choi H S, Rhee W S. IoT home gateway for auto-configuration and management of MQTT devices[C]//2015 IEEE Conference on Wireless Sensors (ICWiSe), 2015: 12-17.
- [11] 施巍松, 孙辉, 曹杰, 等. 边缘计算: 万物互联时代新型计算模型[J]. 计算机研究与发展, 2017, 54(5): 907-924.
- [12] 高彩凤, 于震, 吴剑林. 典型数据机房热环境分析及气流组织优化[J]. 暖通空调, 2013, 43(9): 101-106.
- [13] 赵巧颖, 瞿少成, 张伟刚, 等. 基于物联网的电信运营商机房能耗监控系统[J]. 计算机工程与应用, 2017, 53(22): 204-207.
- [14] 李彦冬, 郝宗波, 雷航. 卷积神经网络研究综述[J]. 计算机应用, 2016, 36(9): 2508-2515.
- [15] 中国电子工程设计院. 电子信息系统机房设计规范: GB50174-2008[S]. 北京: 中国计划出版社, 2009.

(上接第239页)

- [23] Errico F, Desaulniers G, Gendreau M, et al. A priori optimization with recourse for the vehicle routing problem with hard time windows and stochastic service times[J]. European Journal of Operational Research, 2016, 249(1): 55-66.
- [24] Kennedy J E R. Particle swarm optimization[C]//Proceedings of IEEE International Conference on Neural Networks, 1995, 4: 1942-1948.
- [25] Kennedy J, Eberhart R E. A discrete binary version of the particle swarm algorithm[C]//Proceedings of 1997 IEEE International Conference on Systems, Man, and Cybernetics, 1997, 5: 4104-4108.
- [26] Boudia M, Prins C, Reghioui M. An effective memetic algorithm with population management for the split delivery vehicle routing problem[J]. Hybrid Metaheuristics, 2007, 4771: 16-30.
- [27] Prins C. A simple and effective evolutionary algorithm for the vehicle routing problem[J]. Computers & Operations Research, 2004, 31(12): 1985-2002.
- [28] Solomon M M. Algorithms for the vehicle routing and scheduling problems with time window constraint[J]. Operations Research, 1987, 35(35): 254-265.
- [29] Ho S C, Haugland D. A tabu search heuristic for the vehicle routing problem with time windows and split deliveries[J]. Computers & Operations Research, 2004, 31(12): 1947-1964.

(上接第256页)

- [22] Yoon S, Kim E. Temporal classification error compensation of convolutional neural network for traffic sign recognition[J]. Journal of Physics Conference Series, 2017, 806(1).
- [23] Huval B, Wang T, Tandon S, et al. An empirical evaluation of deep learning on highway driving[J]. Computer Science, 2015.
- [24] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. Computer Science, 2014.
- [25] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2014: 1-9.
- [26] Yang Y, Luo H, Xu H, et al. Towards real-time traffic sign detection and classification[C]//IEEE International Conference on Intelligent Transportation Systems, 2014: 87-92.
- [27] Zhu Z, Liang D, Zhang S, et al. Traffic-sign detection and classification in the wild[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2110-2118.
- [28] Abedin Z, Dhar P, Hosseini M K, et al. Traffic sign detection and recognition using fuzzy segmentation approach and artificial neural network classifier respectively[C]//International Conference on Electrical, Computer and Communication Engineering, 2017: 518-523.